

Ausgangslage: Kontextbeschränkungen und externe Gedächtnisschichten

Große Sprachmodelle (LLMs) verlieren bei sehr langen Gesprächsverläufen an Fokus und Kohärenz (sogenannter “Context Rot” [7†L74-L82]). Gleichzeitig steigen Tokenkosten und Rechenaufwand für riesige Kontextfenster. Neuere Arbeiten zeigen, dass nicht bloß die Vergrößerung des Kontextfensters hilft, sondern vielmehr **strukturierte Gedächtnisschichten**. Beispielsweise wandelt das System *Memori* ungeordneten Dialog in kompakte, semantische Tripel und Zusammenfassungen um. Damit erreicht es hohe Schlussfolgerungsqualität, während es nur ein Bruchteil ($\approx 5\%$) der Tokens eines unstrukturierten Kontexts verwendet [18†L69-L75] [18†L125-L132]. In Agenten-Frameworks wird das Konzept eines externen Memories betont: Gedächtnismodule speichern Fakten, Strategien und Zusammenhänge außerhalb des Modells [16†L387-L395] [11†L237-L246]. Diese Befunde stützen unsere Annahme, dass der Schlüssel nicht mehr Wissen im Modell, sondern **bessere Orientierung** im Kontext ist. Strukturiertes Speichern von Gesprächsinhalten (z.B. als YAML-Daten, Mehrschicht-“Trilayer“-Schemata, CREP-Metadaten) könnte es dem LLM ermöglichen, früheres Wissen zuverlässiger zu nutzen und länger kohärent zu bleiben.

Hypothese und theoretischer Rahmen

Wir nehmen an, dass das Modell bereits über das nötige Wissen verfügt, aber ohne externe Struktur rasch „den Überblick verliert“ (hohe semantische Entropie). Durch explizite **Informationspartitionierung** (z.B. Fakten vs. Interpretation vs. Hypothesen im Trilayer) und Metadaten (z.B. *Kohärenz*, *Resonanz*, *Emergenz*, *Plausibilität* im CREP-Schema) können wir den Kontext so gliedern, dass das LLM relevantere Teile leichter identifiziert. Ähnlich wie bei kontextgestützten Gedächtnissystemen [18†L119-L127] senkt dies die Informationsdichte und stabilisiert „Semantische Pfade“ durch den Gesprächsraum. Trilayer entspricht etwa einer Abspaltung in “episodisches” (Fakten) und “semantisches” (Interpretation) Gedächtnis [16†L387-L395], CREP kann wie eine Qualitätsmetrik für jeden Eintrag wirken. Das entspricht bekannten *Context-Engineering*-Prinzipien: Informationsblöcke sollten klar abgegrenzt und hochsignifikant sein [7†L74-L82] [18†L125-L132], um die begrenzte “Aufmerksamkeit” des Modells effizient zu nutzen. Außerdem erwarten wir rekursive Effekte (z.B. selbstgenerierte Inhaltsverzeichnisse oder Zusammenfassungen), da das Modell in YAML oder Dreischicht-Form leichter Wiederverweise erstellen kann.

Experimentelles Design

- **Versuchsgruppen:**
- **Kontrolle:** Standard-Konversation ohne besondere Strukturvorgaben.
- **Gruppe A (YAML):** Jede Antwort des LLM wird komplett als YAML-Dokument formatiert, mit klar hierarchischer Gliederung.
- **Gruppe B (Trilayer):** Die Antworten sind in drei Ebenen gegliedert: *Fakten*, *Interpretationen* und *Hypothesen*. Alle Informationen sollen sich diesen Kategorien zuordnen lassen.

- **Gruppe C (YAML+Trilayer+CREP):** Hier kommt zusätzlich das CREP-Schema mit Feldern wie *Kohärenz*, *Resonanz*, *Emergenz* und *Plausibilität* zum Einsatz, etwa als Metadaten auf oberster YAML-Ebene.
- **Aufgabenstellung:** In allen Gruppen führen wir lange, komplexe Dialoge zu einem Fachthema (z.B. Projektplanung, Forschungsdiskussion, strategische Entscheidungsfindung). Die Gespräche laufen über viele Dutzend bis mehrere Hundert Schritte. Jede Gruppe erhält dieselben Startfragen und Zwischeneingaben, die Antworten müssen je nach Gruppe strukturiert werden. So lässt sich direkt messen, wie die Strukturierung das Gesprächsverhalten beeinflusst.
- **Umsetzung:** Praktisch kann man mit GPT-4o oder vergleichbaren Modellen arbeiten und sie per System- oder User-Prompt zur Strukturierung zwingen. Beispielsweise erhält (A) die Anweisung „Antworten im YAML-Format“, (B) „Nutze die drei Schichten Fakten/Interpretation/Hypothese“, (C) zusätzlich „Füge die CREP-Metafelder ein“. Die Gesprächsdaten werden automatisch protokolliert, parallele Abläufe (A–C und Kontrolle) ermöglichen direkten Vergleich.

Metriken und Auswertung

- **Kohärenz:** Misst, wie stringent das Modell bei sequentiellen Antworten bleibt. Bewertet durch menschliche Rater und/oder automatisierte Ähnlichkeitsmaße (z.B. Embedding-Vergleiche) über längere Segmente **【18†L69-L75】** **【18†L125-L132】** .
- **Abfragegenauigkeit:** Testet, ob das Modell frühere Fakten oder Schlüsse korrekt wiedererkennt. Beispielsweise stellen wir gezielte Kontrollfragen (Quiz) zu früheren Aussagen des Dialogs und vergleichen die Antworten zwischen den Gruppen.
- **Semantische Drift:** Quantifiziert die Abweichung vom ursprünglichen Thema. Man kann z.B. Themenclustering oder Keyword-Vergleiche auf unterschiedlichen Gesprächsabschnitten durchführen. Weniger Drift würde für (B)/(C) sprechen.
- **Kontext-Effizienz:** Verhältnis von Gesamttextränge zu tatsächlich nützlicher Information. Strukturierte Antworten können Redundanz reduzieren. Hier messen wir etwa die prozentuale Reduktion unnötiger Tokens.
- **Reasoning-Depth:** Anzahl nachvollziehbarer Inferenzschritte in den Antworten. Dies lässt sich etwa durch die Kette von Argumenten evaluieren: Je mehr logische Schlussfolgerungen konsistent folgen, desto tiefer die reasoning depth.
- **Navigierbarkeit (User-Evaluierung):** Es wird getestet, wie leicht ein menschlicher Prüfer in einer gesprächstauglichen Datei (z.B. YAML-Protokoll) relevante Informationen findet. Gruppeneingabe könnte mittels Aufgaben gelöst werden wie “Finde, was wir zu Punkt X vor 20 Antworten gesagt haben.” Leichtere Navigation deutet auf bessere Strukturierung hin.

Erwartete Ergebnisse und Hypothesen

Basierend auf voriger Forschung gehen wir davon aus, dass strukturierte Formate (insbesondere Gruppe C) die Kohärenz und Informationsnutzung deutlich steigern. *Memori* zeigt beispielsweise: Solange wir Dialog in formalisierten Formen (Tripel, Zusammenfassungen) ablegen, bleibt Schlussfolgerungsgüte hoch, auch bei minimalem Kontextinput **【18†L69-L75】** **【18†L125-L132】** . Ähnlich legen Experimente mit Kontext-Folding nahe, dass aktive Kontextverdichtung (Zerlegen,

Zusammenfassen) bessere Ergebnisse liefert als unstrukturierte Verlängerung 【5†L49-L57】 . Konkrete Erwartungen:

- **Kohärenz steigern:** (B) und (C) sollten bei Bewahrung komplexer Gesprächszusammenhänge weniger inkonsistente Sprünge produzieren.
- **Drift minimieren:** Strukturierte Kontexte wirken als Attraktoren, so dass das Modell seltener vom Thema abweicht. (C) könnte hier am besten abschneiden.
- **Besserer Abruf:** Durch explizite Fakten-Kategorie oder Indizes (z.B. von Trilayer/CREP) findet das Modell (und auch Menschen) alte Informationen leichter wieder.
- **Effizienz:** Die Gruppen mit Struktur (insb. YAML) vermeiden Doppelungen und fokussieren auf Relevantes, ergo bessere Kontext-Effizienz.
- **Tiefe Reasoning-Ketten:** Wenn das Modell in strukturierter Form antworten muss, wird es gezwungen, jeden Schritt explizit darzulegen. Dadurch könnten tiefere Schlussfolgerungen erhalten bleiben.
- **Falsifikation:** Wenn sich kein signifikanter Unterschied findet – etwa wenn Kohärenz und Abruf für alle Gruppen gleich schlecht sind – wäre damit unsere Hypothese widerlegt.

Theoretische Implikationen und Ausblick

Unser Ansatz verknüpft Forschungsergebnisse zu **Kontext-Engineering** und **Agentenspeicher**. Sieht man LLM-Konversation als dynamisches System, wirken Trilayer/CREP wie externe **Orientierungsschichten** oder „Navigationskarten“: Sie markieren wichtige Knoten und Relationen. Das entspricht dem GenesisAeon-Prinzip „orientieren statt Wissen laden“. Langfristig könnten solche strukturierten Gedächtnis-Protokolle (analog zu Obsidian- oder Git-Workspaces 【14†L39-L48】) ermöglichen, dass mehrere Modelle denselben Kontext teilen und nahtlos weitermachen – ein Ansatz, der bereits erfolgreich demonstriert wurde.

Eine weiterführende Analogie wäre der **Resilienzaspekt**: Wir könnten untersuchen, ob nach „Störungen“ im Gespräch (z.B. abrupte Themenwechsel) die Erholungszeit in (C) kürzer ist – analog zu klimawissenschaftlichen Resilienzmetriken. Dies hätte übergeordnet Interesse, da es zeigt, ob strukturierter Kontext auch in extremeren Bedingungen stabilisierend wirkt.

Praktische Durchführung und Deliverables

Wir planen, ein umfassendes Benchmark-Protokoll zu entwickeln: Dazu gehört ein Evaluationsdatensatz (lange Dialoge aus Wissensdomänen), ein Satz reproduzierbarer Prompts (z.B. spezifische Themenfragen) und automatisierte Analyse-Skripte. Die Gespräche laufen parallel in den vier Varianten. Die **quantitativen Ergebnisse** (Statistiken zu unseren Metriken) werden zusammen mit **qualitativen Auswertungen** (Expertenfeedback) in einem Bericht aufbereitet. Schließlich erstellen wir eine Publikations-Outline, in der wir methodische Details, Daten und Befunde dokumentieren. Im Ergebnis soll klar werden, ob und wie stark strukturierte Kontextarchitekturen die Langzeit-Leistung von LLM-Konversationen verbessern können.

Literaturbelege

Frühere Studien unterstützen unsere Methode: Anthropic betont z.B., dass LLMs „ein begrenztes Aufmerksamkeitsbudget“ für Kontext haben 【7†L74-L82】 . *Memori* zeigt, dass definierte semantische Strukturen (Tripel, Zusammenfassungen) effektiver sind als bloß lange Prompts 【18†L69-L75】

【18†L125-L132】. Agenten-Scaffolding-Arbeiten heben hervor, dass externe Memory-Module (episodisch/semantisch) für kohärente Langzeitarbeit unerlässlich sind 【16†L387-L395】 【11†L237-L246】. Diese Befunde stützen die Idee, dass unser Trilayer/CREP-Konzept eine wirksame **externe Kontexterweiterung** darstellt.
