

Hintergrund und Motivation

Sprachanwendungen sind heute mehrheitlich als **Mehrzug-Gespräche** (Multi-Turn Dialogue) gestaltet. Dabei zeigt sich oft ein **deutlicher Performance-Abfall**, wenn ein LLM über viele Interaktionsrunden hinweg gefordert wird. So belegt Liu et al. (2026), dass LLMs in mehrstufigen Dialogen gegenüber Einzelschritten rund **30 % Leistung einbüßen** („Lost in Conversation“) [22†L47-L55] [22†L105-L112] . Der Grund liegt nicht in fehlendem Wissen, sondern in **Ausrichtungs- und Gedächtnislücken**: Wenn der Benutzer nur fragmentarische Informationen liefert, „ersinnt“ das Modell plausible Aufgabenformulierungen auf Basis allgemeiner Trainingsannahmen und verliert so im Verlauf die individuellen Intentionen aus dem Blick [22†L105-L112] [20†L244-L252] . Klassisches Prompting oder Model-Scaling behebt dieses Problem nicht: Die Antworten degradierten vielmehr auf konservative, „Durchschnitts-User“-Annahmen [20†L244-L252] .

Angesichts dieser Einsichten lautet die zentrale Frage: **Kann explizite Kontextstrukturierung das Modell „orientieren“ und seine Navigation durch das große latente Wissen verbessern?** Eine mögliche Antwort liegt in der Einführung **externen Gedächtnisses** und **Struktur-Layern**. Analog zu Resilienz-Konzepten in komplexen Systemen legt man nahe, ein LLM nicht nur mit unstrukturiertem Wissen auszustatten, sondern mit Wegweisern durch dieses Wissen. Dies entspricht etwa dem *Tri-Layer*-Ansatz, der in der AAS-Forschung Mensch-KI-Workflows in definierte Rollen (Entscheidung, strukturelles Denken, Assistenz) unterteilt [4†L61-L69] , sowie aktuellen Gedächtnisarchitekturen, die Gespräche in **arbeits-, episodischen und semantischen Layern** segmentieren [29†L97-L105] . In der Praxis nutzen Entwickler bereits YAML-basierte DSLs (z.B. PDL), um vielstufige Dialoge deklarativ zu beschreiben und damit den Prompt- und Zustandsaufbau klar vom Modellcode zu trennen [25†L75-L80] [25†L169-L175] .

Verwandte Forschung

- **Multi-Turn-Kohärenz:** Studien zeigen, dass in mehrstufigen Dialogen vor allem *Kontextdrift* und *fehlende Konsistenz* zu Fehlern führen [22†L105-L112] [35†L78-L84] . Ohne Struktur vergessen LLMs frühere Zusagen und drifteten in Nebenthemen ab, was die Benutzerzufriedenheit stark mindert [32†L28-L36] [35†L78-L84] .
- **Mediator-Architekturen:** Liu et al. (2026) schlagen vor, die Aufgabeninterpretation (Intent) vom Ausführungsmodus zu entkoppeln. Ein *Mediator* fasst die Interaktions-Historie zusammen und formuliert sie als explizite, vollständige Instruktion für das Modell neu. Damit gelang es ihnen, ca. **20–21 %** der verlorenen Performance wiederzuerlangen, da das Modell eine präzisere „Niedrig-Entropie“-Anweisung erhält [22†L134-L142] [20†L250-L258] .
- **Hierarchisches Gedächtnis:** Jüngste Arbeiten zeigen, dass ein mehrschichtiges Kontextgedächtnis („arbeits-, episodisch-, semantisch“) die langfristige Konsistenz drastisch verbessert [29†L97-L105] . So wird etwa innerhalb eines Gesprächsnahbereichs („working memory“) gearbeitet, über Sessions hinweg ein komprimiertes Protokoll geführt und Fakten in einer semantischen Ebene abgelegt. Dieses Design senkt nicht nur den Kontextverbrauch, sondern vermindert „False Memories“ und erhöht die Gesamtgenauigkeit [29†L97-L105] .
- **Strukturiertes Prompting:** YAML-basierte Promptsprachen wie PDL legen dialogische Abläufe **explizit und mehrstufig** fest. Sie ermöglichen es, dass jeder Prompt-Block ein zusammenhängender Teil des Gesprächs ist und die Modellaufrufe automatisch mit dem richtigen Kontext verknüpft werden. Anwender berichten, dass so „keine komplexe

Zustandsverwaltung“ mehr nötig ist – die Konversationslogik wird deklarativ und leicht nachvollziehbar [25†L75-L80] [25†L169-L175] .

- **Kontextdrift & State Management:** Fachartikel betonen, dass Drift genau durch fehlende Zustandsverwaltung entsteht. Ohne explizite Gedächtnisschicht muss das Modell ständig aus begrenztem Verlauf rekonstruieren [32†L84-L93] . Das erhöht Fehler. Experten empfehlen darum Systeme wie Retrieval-gestützte Generation und formale Status-Speicher, um den Orientierungssinn des Modells zu stabilisieren [32†L28-L36] [32†L84-L93] .

Methodik und Experimentdesign

Wir planen ein kontrolliertes Experiment mit **vier Versuchsgruppen**: (1) *Kontrolle*: konventionelles Dialog-Prompting ohne Struktur. (2) *YAML*: alle Antworten des LLM werden als strenge YAML-Strukturen formatiert. (3) *Trilayer*: dieselben YAML-Antworten, aber mit Aufteilung in drei Ebenen (*layer1: Fakten*, *layer2: Interpretation*, *layer3: Hypothesen*). (4) *YAML + Trilayer + CREP*: zusätzlich zu Trilayer werden noch **CREP-Metafelder** (Coherence, Resonance, Emergence, Plausibility) an jede Antwort angehängt. Diese Schichtung entspricht der Idee, Wissen eindeutig zu partitionieren und umfangreiche Semantik anzureichern.

- **Daten & Codebasis:** Zunächst sammeln wir alle relevanten Repositorien (z.B. *genesis-os*, *aeon-ai* etc.) und Dokumentationen aus dem GenesisAeon-Portfolio (via GitHub) sowie wissenschaftliche Artikel zu Kontextgedächtnis und Prompt-Architekturen [25†L75-L80] [29†L97-L105] .
- **Gesprächs-Skript:** Ein standardisiertes Thema oder Korpus wird vorbereitet (z.B. eine rollenspielartige Dialogaufgabe über mehrere Sitzungen). Dieselben Inhalte werden über alle Gruppen hinweg gestreut.
- **Prompt-Sets:** Für jede Gruppe definieren wir klare Eingabeaufforderungen – z.B. Aufforderungen, wie der Agent antworten soll (freitext vs. YAML-Template vs. Trilayer-Schema). Diese Prompt-Sets werden versioniert und sind vollständig reproduzierbar.
- **Metriken:** Zur Evaluation messen wir **Kohärenz**, **Abruffähigkeit**, **semantischen Drift**, **Kontext-Effizienz**, **Reasoning-Tiefe** und **User-Navigierbarkeit**:
 - *Kohärenz*: Grad, in dem das Gespräch logisch fortgeführt wird (z.B. keine unerwarteten Themenwechsel oder Widersprüche). Entspricht den von Ip (2026) genannten „Konversationskohärenz“-Metriken [35†L78-L84] .
 - *Abrufgenauigkeit*: Fähigkeit, früher genanntes korrekt wiederzuverwenden. Hier messen wir zum Beispiel, wie exakt Fakten aus früheren Turns reproduziert werden.
 - *Semantischer Drift*: Ausmaß, in dem sich Themen/Schlüsselbegriffe vom Ausgangspunkt entfernen. Ein hoher Driftwert signalisiert Vergessen. (Dies korrespondiert mit dem bei Maxim (2025) beschriebenen Drift-Phänomen [32†L28-L36] .)
 - *Kontext-Effizienz*: Verhältnis der insgesamt zur Verfügung stehenden Kontextlänge zur tatsächlich effektiv genutzten Länge. Werten aus vorheriger Arbeit zufolge kann strukturierter Kontext die nötige Kontextmenge reduzieren [29†L97-L105] [35†L78-L84] .
 - *Reasoning-Tiefe*: Anzahl der Schlussfolgerungsschritte oder Zwischenergebnisse im Gedankengang, bevor eine finale Antwort entsteht. Wir analysieren z.B. die Länge von Ketten oder die Nachvollziehbarkeit von Argumentationsschritten.
 - *Recovery Time*: (Neu) Anzahl Interaktionen bis das Modell nach einer absichtlichen Störung wieder zum ursprünglichen semantischen Pfad zurückfindet. Dieses Konzept lehnen wir an Analoga aus Klimasystemen an (Resilienz/Erholungszeit).
- *User-Navigierbarkeit*: Subjektive Metrik: In wie weit können menschliche Teilnehmer ein vorheriges Thema oder Argument aus dem strukturierten Verlauf rekonstruieren?

- **Experimentdurchführung:** Jede Gruppe führt **mehrere Sitzungen** mit demselben Modelltyp durch (z.B. GPT-4o mit gleichbleibender Temperatur). Wir nutzen automatisierte Messpipelines (z.B. das Open-Source-Framework DeepEval [35†L78-L84] [35†L87-L90]) und ergänzen es um spezifische Tests (z.B. Faktenfragerunden zur Abrufgenauigkeit, Intent-Tracking-Tests).

Erwartete Ergebnisse und Hypothesen

Basierend auf der Literatur erwarten wir: **Strukturierte Kontext-Layer erhöhen die multi-turn Performance**. Insbesondere sollte sich zeigen:

- **Reduzierter Drift und höhere Kohärenz:** Durch deklarative Kontextstrukturen (YAML) und explizite Layer stabilisiert sich der Dialogverlauf. Modelle "verlieren" den Faden weniger schnell [25†L75-L80] [32†L84-L93] .
- **Bessere Nutzung des Wissens:** Mit klar getrennten Fakten-/Interpretations- und Hypothesen-Layern (Trilayer) ist das Modell gezwungen, mehr Kontextpunkte gleichzeitig zu adressieren, was die effektive Kontextnutzung steigert. Ähnlich wie der Mediator-Ansatz sollte dies die Entropie der Kontextinformationen senken [22†L134-L142] [20†L244-L252] .
- **Erhalt von Kritikfähigkeit:** Die Vorarbeit legt nahe, dass klare Struktur eher *gerade Kooperationsbereitschaft und kritische Distanz zugleich* steigert – entgegen der üblichen Annahme, dass mehr Zusammenarbeit zu weniger Kritik führt. Unsere vorläufigen Beobachtungen deuten darauf hin, dass Modelle in strukturierten Settings weiterhin Widersprüche erkennen, ohne dabei „zahmer“ zu werden.
- **Quantitative Verbesserungen:** Wir erwarten messbare Zuwächse in unserem Kohärenz-Score sowie in der Retrieval-Genauigkeit, während semantic drift signifikant sinkt. Auch Metriken wie „Knowledge Retention“ und „Conversational Coherence“, die in der Praxis als Schlüssel für Multi-Turn-Agenten gelten [35†L78-L84] , sollten sich verbessern.

Ein besonders interessanter Effekt könnte die *Empowerment*-Dimension sein: Wenn LLMs durch externe Strukturen „navigierbar“ werden, könnten sie selbstständig Index- oder Zusammenfassungsstrukturen generieren (Emergentes Behavior). Das könnte zu einer dramatischen Reduktion von Halluzinationen und einer besseren Domain-Integration führen.

Nächste Schritte und Deliverables

Aus dieser Untersuchung wird ein vollständiger Evaluations-Workflow entstehen. Dazu gehören:

- **1. Repositorium und Dokumentensammlung:** Vollständiges Mapping aller relevanten GenesisAeon-Repos (z.B. *genesis-os*, *aeon-ai*, *unified-mandala*) sowie themenrelevanter Publikationen und Präsentationen (u.a. Tri-Layer-Serie [4†L7-L10] [4†L61-L69]).
- **2. Forschungsüberblick:** Eine systematische Literaturübersicht zu Kontextstrukturierung, externem Gedächtnis und mehrstufigen Prompt-Sprachen, mit Annotierungen und Schlüsselzitaten (z.B. Zielformulierungen von Liu et al. 2026 [22†L105-L112] [20†L244-L252] oder Kontexteffizienz bei PDL [25†L169-L175]).
- **3. Experiment-Design-Dokument:** Detaillierte Beschreibungen aller Versuchsgruppen, Prompt-Formate, Gesprächsszenarien und Tools (inklusive ggf. Pseudo-Code oder Diagrammen zur Interaktion).
- **4. Benchmark-Protokoll:** Konkrete Spezifikation von Testfällen und Messverfahren für jede Metrik (z.B. *Zeitschemata* für Recovery-Time-Störungen, Abfragekataloge für Abrufttests, Kohärenz-Scoring).

- **5. Evaluationsdatensatz:** Gezielter Datensatz oder generative Szenarien, der reale Multi-Turn-Aufgaben widerspiegelt (z.B. Verlaufsprotokolle aus Chatlogs, Domain-spezifische Fragen).
- **6. Reproduzierbare Prompt-Sets:** Vollständige YAML- und Trilayer-Skripte für beide Experimente, so dass Dritte sie eins zu eins nachstellen können.
- **7. Ergebnisse & Analyse:** Quantitative Auswertungen (Tabellen, Plots) zu den Metriken sowie qualitative Fallstudien (z.B. Dialogbeispiele). Dabei werden Wirksamkeit und Grenzen jeder Struktur evaluiert.
- **8. Veröffentlichungsskizze:** Gliederung und Kernergebnisse für einen wissenschaftlichen Bericht oder Konferenzartikel, um diese Erkenntnisse mit der Community zu teilen.

Ausblick

Diese Studie erweitert den Kontext von Prompt Engineering zu einer **Architektur-Angelegenheit**: Indem wir LLMs nicht nur **Speicherplätze** (Memory) geben, sondern **Orientierungsmarkierungen** (Semantische Pfade, Indexschichten), testen wir, ob dadurch ein quasi-externalisiertes Gedächtnis entsteht. Gelänge es, Modelle hierdurch dauerhaft kohärent und kritikfähig zu halten, entstünde ein neues Feld zwischen *Context Engineering*, *externem Gedächtnis* und *Mensch-KI-Zusammenarbeit*. Unser Hauptanliegen ist nicht, Modelle gefügiger zu machen, sondern sie „selbstbewusster“ im eigenen Wissen navigieren zu lassen, ohne ihre Fähigkeit zur kritischen Rückfrage zu opfern.

Falls die Ergebnisse unsere Hypothesen bestätigen, hätten wir eine starke Argumentation dafür, dass **formale Kontextstrukturen** einen fundamentalen Fortschritt für LLM-basierte Anwendungen darstellen – nicht nur als Prompt-Trick, sondern als integrierter Baustein intelligenter Systeme. Solch strukturierte Rahmenwerke könnten letztlich zum Standard werden, um die innere Komplexität von LLMs für Menschen durchschaubar und handhabbar zu machen.

Quellen: Relevante Studien und Quellen wurden eingebunden, u. a. Liu et al. 2026 [22†L47-L55] [22†L105-L112] zur Problembeschreibung, Arbeiten zu Erinnerungsschichten [29†L97-L105] , zu strukturierten Promptsprachen [25†L75-L80] [25†L169-L175] und zu Kontextdrift [32†L28-L36] [32†L84-L93] , sowie Praxisempfehlungen zur Multi-Turn-Evaluierung [35†L78-L84] [35†L87-L90] .
